Ankara Esenboğa Havalimanı'nda Sis ve Düşük Görüş Koşullarının Açıklanabilir Makine Öğrenmesiyle Kısa Vadeli Tahmini

Ata Sakik

***Özet*—Sis, Ankara Esenboğa Uluslararası Havalimanı'nda (LTAC) gecikme, yönlendirme ve iptallerin başlıca meteorolojik nedenidir ve havalimanındaki sis gözlemlerinin yarısından fazlası CAT II/III yaklaşma prosedürleri gerektirmektedir. Bu çalışmada LTAC için ilk makine öğrenmesi tabanlı düşük görüş kısa vadeli tahmin (nowcasting) sistemi sunulmaktadır. Kalite kontrolünden geçirilmiş 21,8 yıllık (2005–2026) METAR/SPECI rasatları kullanılarak sis (hâkim görüş mesafesi 1000 m'nin altında) ve ILS kategorilerine karşılık gelen pist görüş mesafesi (RVR) sınıfları; anlık durumu, eğilimleri, sınır tabaka belleğini ve Güneş döngüsünü tanımlayan 77 öznitelikle 1, 3 ve 6 saat önceden tahmin edilmiştir. Lojistik regresyon, rastgele orman, XGBoost, LightGBM ve çok görevli GRU/LSTM ağları kronolojik olarak eğitilmiş, kalibre edilmiş ve dört bağımsız sis sezonunda (2022–2026) kalıcılık, klimatoloji ve resmî METAR TREND tahminiyle karşılaştırmalı olarak doğrulanmıştır. Tüm modeller her öngörü süresinde kalıcılık tahmininden anlamlı biçimde daha başarılıdır: en iyi kritik başarı indeksi 1, 3 ve 6 saat için sırasıyla 0,73, 0,47 ve 0,34 olup kalıcılıkta bu değerler 0,65, 0,32 ve 0,13'tür; 1 saatte LightGBM, TREND tahminini 0,105 (%95 güven aralığı 0,075–0,140) farkla geçmektedir. Gradyan artırma yöntemleri 1 saatte, yinelemeli ağlar ise 3–6 saatte en yüksek olasılıksal beceriyi sağlamaktadır. SHAP analizi, belirleyici etkenlerin 1 saatte anlık nem ve görüş durumundan 6 saatte sınır tabakanın nem belleğine ve gün doğumuna kalan süreye fiziksel olarak tutarlı biçimde kaydığını göstermektedir. Kalibre edilmiş modeller; kademeli uyarı üreten, her tahmini açıklayan ve kendini gerçek zamanlı doğrulayan açık kaynaklı bir web uygulamasında hizmete sunulmuştur.**

***Anahtar Kelimeler*—Açıklanabilir yapay zekâ, düşük görüş prosedürleri, gradyan artırma, havacılık meteorolojisi, kısa vadeli tahmin, pist görüş mesafesi, sis, yinelemeli sinir ağları.**

I. GİRİŞ

SİS, yer seviyesindeki yatay görüş mesafesini 1000 m'nin altına düşüren ve havacılık için en fazla aksaklığa yol açan meteorolojik olaylardan biridir [1], [2]. Görüş mesafesi veya pist görüş mesafesi (RVR), mevcut aletli iniş sistemi (ILS) kategorisinin minimumlarının altına indiğinde havalimanı düşük görüş prosedürlerini (LVP) uygulamak, geliş kapasitesini düşürmek ya da trafiğe kapanmak zorunda kalır; bu da ağ genelinde gecikme, yönlendirme ve iptallere neden olur [3]. Başkentin ana kapısı olan Ankara Esenboğa Uluslararası Havalimanı (LTAC) bu açıdan özellikle hassastır: sislerin yaklaşık %89'u Ekim–Şubat döneminde görülmekte, büyük bölümü RVR'yi 350 m'nin altına düşürmekte ve yaklaşık dörtte üçü radyasyon sisidir [4]; 2011–2020 döneminde yaklaşık 800 saat sis kaydedilmiş, Aralık 2019'daki tek bir olay ise yaklaşık üç gün sürmüştür [5].

Bu operasyonel önemine karşın Esenboğa üzerine yayımlanmış çalışmalar klimatolojik ve sinoptik niteliktedir. Çamalan vd. [4] 2000–2009 gözlemlerini incelemiş ve sis tahmin modellerinin geliştirilmesini açıkça önermiş; Koyuncu vd. [5] on yıllık bir analizi sinoptik bir olay incelemesiyle birleştirmiştir. Bildiğimiz kadarıyla LTAC için makine öğrenmesi (ML) tabanlı bir sis veya düşük görüş tahmini geliştirilmemiştir. Uluslararası ölçekte istatistiksel ve ML tabanlı sis ve düşük görüş prosedürü tahminleri, Viyana gibi havalimanlarında [6]–[8] ve pek çok başka konumda [9], [10] kalıcılık tahminine göre açık bir üstünlük göstermiştir; ancak veriye dayalı tahminleri resmî meydan tahminleriyle aynı bilgi ufkunda karşılaştıran ve modellerin öğrendiklerini fiziksel olarak açıklayan çalışma sayısı azdır.

Bu çalışma söz konusu boşlukları LTAC için kapatmaktadır. Katkılar şunlardır:

1) Sis istatistikleri havalimanının yayımlanmış klimatolojisini yeniden üreten, 21,8 yıllık (2005–2026) ve kalite kontrolünden geçirilmiş bir METAR/SPECI veri seti; veri seti tüm kaynak kodlarla birlikte açık olarak paylaşılmaktadır.

2) Altı model ailesinin—lojistik regresyon, rastgele orman, XGBoost, LightGBM, GRU ve LSTM—1, 3 ve 6 saatlik sis ve ILS kategorisi tahminleri için olasılık kalibrasyonu, sınıf dengesizliği deneyi ve gün-blok bootstrap anlamlılık testleriyle kalıcılık, klimatoloji ve resmî METAR TREND (operasyonel pencerede ayrıca TAF) tahminlerine karşı karşılaştırılması.

3) RVR/ILS kategorisi tahmininin sıralı (ordinal) bir problem olarak kurgulanması ve operasyonlar için en kritik olaylar olan sis başlangıç ve dağılmalarının ayrıca incelenmesi.

4) Öğrenilen ilişkileri sis fiziğiyle ilişkilendiren ve belirleyici etkenlerin öngörü süresine göre nasıl değiştiğini gösteren SHAP tabanlı bir açıklanabilirlik analizi.

5) Aynı işlem hattını canlı METAR'larla çalıştıran, açıklamalı kademeli uyarılar üreten ve kendi tahminlerini gerçek zamanlı doğrulayan açık kaynaklı web tabanlı bir erken uyarı uygulaması.

Makalenin geri kalanı şöyle düzenlenmiştir: Bölüm II ilgili çalışmaları, Bölüm III havalimanını ve veriyi, Bölüm IV

Bu çalışma, Ankara Üniversitesi Yazılım Mühendisliği Bölümü YMH453 Makine Öğrenmesi dersinin 2026–2027 güz dönemi projesi olarak hazırlanmıştır. Veri seti, kaynak kodlar, eğitilmiş modeller ve web uygulaması https://github.com/AtaSakik/esenboga-fog-nowcasting adresinde açık olarak paylaşılmaktadır.

A. Sakik, Ankara Üniversitesi Yazılım Mühendisliği Bölümü 4. sınıf öğrencisidir, Ankara, Türkiye (öğrenci no. 25290085; e-posta: atasakik0077@hotmail.com).

yöntemi, Bölüm V bulguları sunmakta; Bölüm VI sonuçların anlamını ve sınırlılıkları tartışmakta, Bölüm VII ise çalışmayı sonuçlandırmaktadır.

II. İLGİLİ ÇALIŞMALAR

A. Sis Fiziği ve Esenboğa

Sis, yere yakın hava ışınımsal soğuma, nemli hava adveksiyonu ya da buharlaşmayla nemlenme sonucu doygunluğa ulaştığında oluşur; Güneş ısıtması, karışım veya kuruma ile dağılır [1]. ParisFog gibi saha çalışmaları, radyasyon sisinin yaşam döngüsünün ışınımsal soğuma, türbülans, aerosoller ve yüzey nemi arasındaki hassas bir dengeyle denetlendiğini göstermiştir [2]; sayısal hava tahmin modellerinin sisi tahmin etmekte hâlâ zorlanmasının nedeni de budur [1], [11]. Esenboğa'da Çamalan vd. [4], 2000–2009 dönemindeki sisli günlerin %75'inin radyasyon sisi olduğunu ve sis gözlemlerinin çoğunun CAT III aralığına (RVR < 350 m) düştüğünü bulmuş; Koyuncu vd. [5] ise Aralık 2019'daki uzun süreli bir olayı kalıcı bir antisiklon ve güçlü bir alçak seviye inversiyonuyla ilişkilendirmiştir.

B. Havalimanlarında İstatistiksel ve Makine Öğrenmesi Tabanlı Kısa Vadeli Tahmin

İlk veriye dayalı yaklaşımlar Canberra'da sis için [12], ABD havalimanlarında bulut tavanı ve görüş için [13] ve olasılıksal görüş tahmini için [14] yapay sinir ağlarını kullanmıştır. Herman ve Schumacher [11] havacılık için sis ve görüş kılavuzunu iyileştirmek amacıyla yeniden tahminleri (reforecast) son işlemden geçirmiştir. Viyana Uluslararası Havalimanı için Kneringer vd. [6] sıralı düşük görüş prosedürü durumlarını sıralı lojistik regresyonla 2 saate kadar tahmin etmiş; Dietz vd. ağaç tabanlı modellerin [7] ve artırma (boosting) yöntemlerinin [8] farklı planlama ufuklarında bu tahminleri iyileştirdiğini göstermiştir. Guijo-Rubio vd. [15] sise bağlı düşük görüşü sıralı bir sınıflandırma problemi olarak ele almış, Castillo-Botón vd. [16] ise çok sayıda ML yönteminin regresyon ve sınıflandırma formülasyonlarını karşılaştırmıştır. Derin öğrenme yaklaşımları havalimanı görüşü için derin ağlardan [17] ve klimatolojik veriyle görüş tahmininden [18] üç boyutlu evrişimli FogNet modeline [19] kadar uzanmaktadır. Güncel derleme çalışmaları [9], [10] bu yöntemlerin potansiyelini doğrulamakla birlikte tutarsız doğrulama uygulamalarına, resmî tahminlerle nadiren yapılan karşılaştırmalara ve modellerin konumlar arasında sınırlı aktarılabilirliğine [20] dikkat çekmektedir.

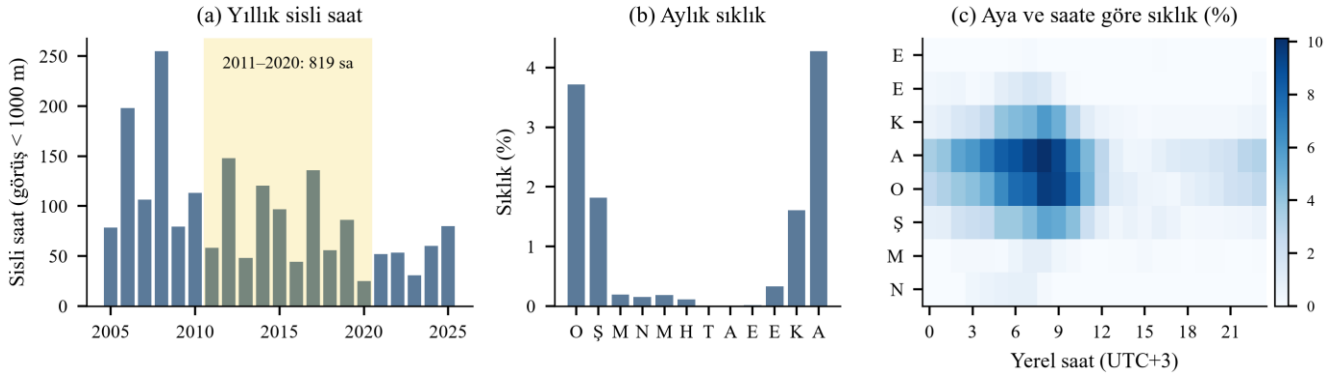
C. Açıklanabilir Yapay Zekâ ve Tahmin Doğrulama

Açıklanabilirlik, ML tahminlerinin tahminciler tarafından benimsenmesi için temel bir koşuldur [21]. SHAP değerleri [22], ağaç topluluklarında tam olarak hesaplanabilen [23], toplamsal ve yerel olarak doğru katkı değerleri sağlar. Meydan tahminleri olasılık tablosundan türetilen kategorik skorlarla doğrulanır [24], [25]; TAF ve TREND değişim grupları içerdiğinden en doğru biçimde bir tahmin koşulları aralığı olarak yorumlanır [26]. Bu çalışma; kalibre edilmiş ML'yi, sıralı ILS kategorilerini, resmî tahminlerle doğrudan karşılaştırmayı ve SHAP açıklamalarını, daha önce veriye dayalı bir sis tahmini bulunmayan bir havalimanı için operasyonel olarak çalışan tek bir sistemde birleştirmektedir.

III. ÇALIŞMA ALANI VE VERİ

A. Esenboğa Havalimanı ve Sis İklimi

Ankara Esenboğa Uluslararası Havalimanı (40,13° K, 32,99° D), şehir merkezinin yaklaşık 28 km kuzeydoğusunda, 953 m yükseklikte bir plato üzerinde yer almaktadır. Karasal iklimi; uzun kış gecelerini, sık görülen antisiklonik durgunluğu, kar örtüsünü ve cephesel yağışlar sonrasında nemli sınır tabakaları bir araya getirir—bunlar ışınımsal soğumayı ve sisi destekleyen koşullardır [4], [5]. Şekil 1, kullanılan veri setindeki sis iklimini özetlemektedir. Sis neredeyse yalnızca soğuk sezona özgüdür: hâkim görüşün 1000 m'nin altında olduğu yarım saatlik gözlemlerin %94,6'sı Ekim–Şubat aylarındadır; sıklık Aralık'ta %4,3, Ocak'ta %3,7'dir ve Haziran–Eylül döneminde pratikte sis görülmez. Gün içinde sis en sık gün doğumu civarında (yerel saatle 08, %2,8), en seyrek ise 15'te görülmektedir. 2011–2020 için hesapladığımız 819,5 saatlik sis süresi, Koyuncu vd. [5] tarafından aynı on yıl için bildirilen yaklaşık 800 saatle çok iyi örtüşmektedir; RVR ≤ 350 m olan sis gözlemlerinin payı (%55,5) da Çamalan vd.'nin [4] sislerin çoğunun CAT III operasyonu gerektirdiği bulgusunu doğrulamaktadır. 537 sis olayı kısa sürelidir—medyan 2 saat—ancak 90. yüzdelik 9 saate ulaşmakta ve en uzun olay 35,5 saat sürmektedir; dolayısıyla operasyonel sorun büyük ölçüde sisin başlangıç ve dağılma zamanlamasıdır. Yıllık sisli saat sayısı belirgin biçimde azalmıştır: 2005–2012'de yılda yaklaşık 130 saatten 2020–2025'te yılda yaklaşık 50 saate.



Şekil 1. LTAC'nin sis iklimi, 2005–2026 (hâkim görüş < 1000 m). (a) Yıllık sisli saat sayısı; gölgeli 2011–2020 dönemi Koyuncu vd. tarafından incelenen dönemdir. (b) Yarım saatlik gözlemlerde sisin aylık sıklığı. (c) Ay ve yerel saate (UTC+3) göre sıklık.

B. Gözlemler ve Resmî Tahminler

Çalışmada Ocak 2005–Ekim 2026 dönemine ait yarım saatlik rutin METAR'lar (HH:20 ve HH:50 UTC) ve özel SPECI rasatları kullanılmıştır. Orijinal rasat metinleri Iowa Environmental Mesonet (IEM) arşivinden alınmıştır [27]. Eski IEM kayıtları, NCEI Integrated Surface Database'den yeniden oluşturulmuş rasatlar da içermektedir; bunlar RVR ve TREND gruplarından yoksun olduğu ve görüşü statü mil adımlarıyla verdiği için çıkarılmış, oluşan boşluklar Ogimet arşivinden alınan orijinal metinlerle doldurulmuştur [28]. Her METAR, tahmincinin resmî çok kısa vadeli tahmini olan 2 saatlik TREND tahminini (NOSIG, BECMG veya TEMPO grupları) içermektedir. Meydan tahminleri (TAF; 24 saat geçerli, günde dört kez yayımlanan) yalnızca son 30 gün için NOAA Aviation Weather Center veri servisinden [29] elde edilebilmiştir; tarihsel TAF arşivine güvenilir biçimde erişilemediğinden TAF karşılaştırması operasyonel dönemde yapılmıştır.

Tüm rasatlar, hâkim ve minimum görüşü, her pistin RVR değerini, mevcut ve yakın geçmiş hadiseleri, bulut katmanlarını ve dikey görüşü, sıcaklığı, çiy noktasını, QNH'yi ve TREND/TAF değişim gruplarını çözümleyen, bu çalışma için geliştirilmiş bir WMO FM 15/FM 51 çözücüsüyle [30] işlenmiştir; çözücü sık görülen yazım hatalarını da (ör. "NO SIG", "Q1 015") düzeltmektedir. Kalite kontrolü kapsamında NIL ve bozuk rasatlar çıkarılmış, fiziksel aralık denetimleri ve çiy noktası tutarlılık denetimi uygulanmış, sıcaklık, çiy noktası ve basınçtaki tekil sıçramalar giderilmiştir. Elde edilen veri seti Tablo I'de özetlenmiştir.

TABLO I
LTAC VERİ SETİNİN ÖZELLİKLERİ

Büyüklük	Değer
Dönem (UTC)	01/2005 – 10/2026
METAR / SPECI rasatı (KK sonrası)	381 408 / 3 610
Kaynak: IEM / Ogimet (boşluk dolgu)	364 028 / 20 990
KK ile çıkarılan/düzeltilen rasat	109 / 47
30 dk analiz dilimi (gözlemli)	382 607 (%99,7)
Görüş < 1000 m dilimleri (oran)	3 884 (%1,02)
Sis olayı; medyan / P90 süre	537; 2,0 sa / 9,0 sa
Görüş < 1500 m iken RVR raporu	%99,9
RVR ≤ 350 m olan sis dilimleri	%55,5

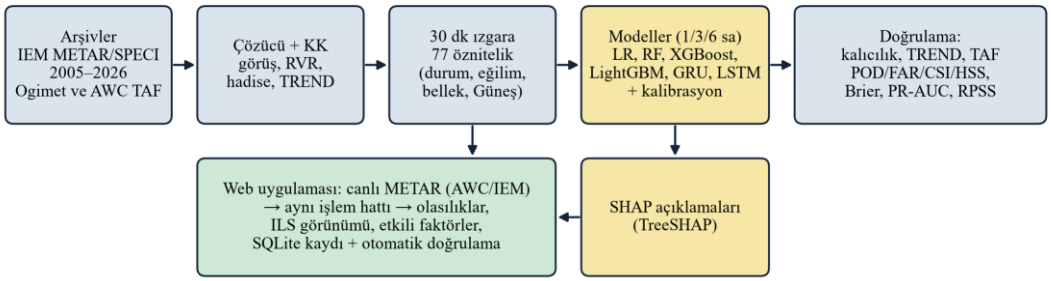
C. Analiz Izgarası ve Tahmin Edilen Değişkenler

Rasatlar, rutin gözlem saatleriyle hizalı düzenli 30 dakikalık bir ızgaraya aktarılmıştır. Izgara zamanı t'deki durum, $(t-29\,\text{dk}, t]$ aralığında yayımlanan son rasattır; böylece rutin saatler arasındaki SPECI'ler hesaba katılır, ancak hiçbir değer enterpole edilmez veya ileri taşınmaz. 382 607 ızgara diliminin %99,7'sinde gözlem bulunmaktadır.

Öngörü süreleri $h \in \{1, 3, 6\}$ saat için geçerlilik zamanı $t+h$'de iki hedef değişken tanımlanmıştır. İkili sis olayı, ICAO/WMO sis eşiği olan 1000 m'nin altındaki hâkim görüştür [31]. ILS kategorisi, tüm pistlerde raporlanan en düşük RVR'ye dayanan sıralı bir değişkendir: RVR ≥ 550 m için sınıf 0 (CAT I veya daha iyi), 350 ≤ RVR < 550 m için sınıf 1 (CAT II) ve RVR < 350 m için sınıf 2 (CAT III). Bu sınırlar Çamalan vd.'nin [4] LTAC için kullandığı kategorileri ve ICAO'nun her hava koşulunda operasyon ile RVR raporlamasına ilişkin kılavuzlarını [32], [33] izlemektedir; güncel CAT II minimumları 300 m'ye kadar RVR'ye izin verdiğinden 350 m sınırı bir miktar ihtiyatlıdır. RVR yalnızca görüş veya RVR 1500 m'nin altındayken raporlandığından, RVR grubu bulunmayan ve görüşü ≥ 1500 m olan dilimler sınıf 0 kabul edilmiş; RVR'nin eksik olduğu düşük görüşlü dilimlerin %0,06'sında ise ihtiyatlı bir yaklaşık değer olarak hâkim görüş kullanılmıştır.

IV. YÖNTEM

Şekil 2, arşivlerden doğrulanmış tahminlere ve operasyonel uygulamaya uzanan veri akışını göstermektedir.



Şekil 2. Çalışmanın ve operasyonel erken uyarı uygulamasının veri akışı. Web uygulaması, çevrimdışı çalışmanın çözücüsünü, kalite kontrolünü, öznitelik işlem hattını ve kalibre edilmiş modellerini yeniden kullandığından çevrimdışı ve çevrimiçi tahminler birebir aynıdır.

A. Problem Tanımı

Gözlem bulunan her ızgara zamanı t için bir f_h modeli

$$p_h(t) = P(y(t+h) = 1 \mid \mathbf{x}(t)) \qquad (1)$$

olasılığını tahmin eder; burada $\mathbf{x}(t)$ yalnızca t anında veya öncesinde yayımlanan rasatlardan hesaplanan öznitelik vektörüdür. $p_h(t)$ bir τ_h eşiğini aştığında uyarı verilir. ILS kategorisi Frank ve Hall'un [34] sıralı ayrıştırmasıyla tahmin edilmektedir: iki ikili model $P_{550}=P(\mathrm{RVR}<550\,\mathrm{m})$ ve $P_{350}=P(\mathrm{RVR}<350\,\mathrm{m})$ olasılıklarını kestirir; sınıf olasılıkları $1-P_{550}$, $P_{550}-P_{350}$ ve P_{350} olarak elde edilir ve $P_{350} \leq P_{550}$ koşulu zorunlu kılınır.

B. Öznitelik Mühendisliği

77 öznitelik gruplar hâlinde Tablo II'de özetlenmiştir. Öznitelikler şunları tanımlar: (i) anlık durum—görüş, RVR, sıcaklık T, çiy noktası T_d, çiy noktası farkı $T-T_d$, Magnus formülüyle hesaplanan bağıl nem [35], rüzgâr bileşenleri, sakin rüzgâr göstergesi, QNH, bulut tavanı, bulut tabanı ve kapalılığı; (ii) mevcut hadise (sis, sığ veya yamalı sis, pus, kurudumanı, çisenti, yağmur, kar); (iii) özellikle gece soğuması ile yüzey tabakasının kuruması veya nemlenmesini yansıtan 1, 3 ve 6 saatlik eğilimler; (iv) 12 saatlik maksimumdan bu yana soğuma, önceki 6–72 saatteki sis, pus, yağış ve kar oranları ve son sisten bu yana geçen süre gibi bellek terimleri; (v) NOAA Güneş konumu denklemleriyle [36] hem tahmin hem geçerlilik zamanında hesaplanan Güneş yükseklik açısı ve gün doğumuna kalan süre dahil takvim ve astronomik terimler. Geçerlilik zamanına ait astronomik terimler deterministik olduğundan önceden bilinmeleri meşrudur.

TABLO II
ÖZNİTELİK GRUPLARI (77 ÖZNİTELİK)

Grup	n	İçerik
Anlık durum	21	Görüş, RVR, T, Td, T−Td, BN, rüzgâr (u, v, sakin, hamle), QNH, tavan, bulut tabanı ve kapalılığı, VV
Hadise	11	FG, MIFG/BCFG/PRFG, VCFG, FZFG, BR, HZ, DZ, RA, SN, yakın zamanda yağış
Eğilimler	19	T, Td, T−Td, log görüşün 1/3/6 sa değişimi; BN, rüzgâr, QNH (3/12 sa), tavan
Bellek	13	12 sa maks.'tan soğuma, min T−Td, maks. BN, sis/pus/yağış/kar oranları, son sisten beri süre, SPECI yaşı
Takvim ve Güneş	13	günün saati ve yılın günü (sin/cos), Güneş yüksekliği, gece, gün doğumuna kalan / batımından beri süre; geçerlilik anında

C. Modeller

Standartlaştırılmış ve medyanla doldurulmuş girdilerle lojistik regresyon (LR) [37] istatistiksel temel modeldir. Rastgele ormanlar (RF) [38] ile gradyan artırma kütüphaneleri XGBoost [39] ve LightGBM [40] ağaç topluluklarını temsil etmektedir; her iki artırma kütüphanesi eksik değerleri doğrudan işleyebilmekte olup hiperparametreleri Optuna'daki [41] ağaç yapılı Parzen kestiricisiyle 30 denemede, erken durdurma kullanılarak ve doğrulama PR-AUC değeri en büyüklenecek biçimde ayarlanmıştır. RF ve LR için küçük doğrulama ızgaraları kullanılmıştır. Zamansal örüntüler uzun kısa süreli bellek (LSTM) [42] ve kapılı yinelemeli birim (GRU) [43] ağlarıyla öğrenilmektedir. Tek bir çok görevli ağ, 22 standartlaştırılmış durum değişkeninin ve bir gözlem maskesinin son 12 saatini (24 ızgara adımı) okur, son gizli durumunu bellek ve geçerlilik zamanı öznitelikleriyle birleştirir ve iki katmanlı bir çıkış bloğuyla dokuz görevin (üç hedef × üç öngörü süresi) tamamını tahmin eder. Maskelenmiş ve pozitif sınıf ağırlıklı ikili çapraz entropi, AdamW [44] ile ve ortalama doğrulama PR-AUC değerine göre erken durdurmayla en küçüklenmiş; altı mimari doğrulama sezonlarında karşılaştırılmıştır. Tüm modeller scikit-learn [45] ve PyTorch [46] ile gerçekleştirilmiştir; seçilen ayarlar Ek'te listelenmiştir.

D. Sınıf Dengesizliği ve Kalibrasyon

Sis, gözlemlerin yalnızca %1,0'ını, RVR < 350 m ise yalnızca %0,6'sını oluşturmaktadır. LR ve LightGBM için dört strateji karşılaştırılmıştır [47]: düzeltme yapmamak, sınıf ağırlıklandırma, SMOTE ile aşırı örnekleme [48] ve rastgele alt örnekleme. Yeniden ağırlıklandırma ve örnekleme tahmin olasılıklarını bozduğundan her model; eşleme yapılmadan, Platt ölçeklemesiyle [49] veya izotonik regresyonla [50] yeniden kalibre edilmektedir; yöntem, doğrulama sezonlarında Brier skorunun bir-sezon-dışarıda çapraz doğrulamasıyla seçilmekte [51] ve ardından tüm doğrulama kümesinde yeniden uydurulmaktadır. Uyarı eşiği τ_h, doğrulama kümesinde kritik başarı indeksini (CSI) en büyükleyen değerdir; $F_1=2\,\mathrm{CSI}/(1+\mathrm{CSI})$ olduğundan aynı eşik F_1'i de en büyükler.

E. Eğitim Protokolü ve Veri Sızıntısının Önlenmesi

Veri, sezonlarla hizalı biçimde kronolojik olarak bölünmüştür (Tablo III): eğitim 01/2005–06/2019, doğrulama

07/2019–06/2022 (üç sis sezonu) ve test 07/2022–06/2026 (dört sis sezonu); Temmuz 2026 sonrası operasyonel değerlendirmeye ayrılmıştır. Rastgele bir bölme, bir sis olayının ardışık yarım saatlik örnekleri neredeyse aynı olduğundan bilgi sızıntısına yol açardı [52]. Tüm ayarlama, kalibrasyon ve eşik kararlarında yalnızca doğrulama sezonları kullanılmış, test sezonları yalnızca bir kez değerlendirilmiştir. Otomatik testler, *t* anındaki her özniteliğin *t* sonrasındaki tüm rasatlar silindiğinde değişmediğini ve hedef değişkenin hiçbir zaman *t* anındaki gözlemi yeniden kullanmadığını doğrulamaktadır.

TABLO III
KRONOLOJİK VERİ BÖLÜMLEMESİ

Küme	Dönem	Dilim	Sis	Oran
Eğitim	01/2005–06/2019	253 017	3 130	%1,24
Doğrulama	07/2019–06/2022	52 581	308	%0,59
Test	07/2022–06/2026	70 073	446	%0,64
Operasyonel	07/2026–10/2026	5 749	0	%0,00

F. Karşılaştırma Tahminleri

Kalıcılık (persistence) tahmini, *t*+*h* için o anda gözlenen durumu tahmin eder. Klimatoloji, eğitim dönemindeki geçerlilik zamanının takvim ayı ve UTC saatine koşullu olay sıklığıdır ve Brier beceri skorunun referansıdır. *t* anında yayımlanan METAR'a eklenen TREND $h \leq 2$ saat için değerlendirilmekte; *t*+*h* için TAF tahmini ise *t* anında veya öncesinde yayımlanan son TAF'tan alınmaktadır; böylece tahmincinin bilgi ufku modellerinkine eşitlenmektedir. TREND ve TAF değişim grupları içerdiğinden geçerlilik zamanında bir görüş aralığına dönüştürülmektedir [26]: hâkim okuma temel tahmini, FM gruplarını ve tamamlanmış BECMG değişimlerini; en kötü durum okuması ise ek olarak BECMG geçişlerinin ve TEMPO ile PROB30/40 gruplarının alt sınırını kullanmaktadır. Okuma 1000 m'nin altındaysa sis tahmini verilmiş sayılır.

G. Doğrulama

a isabet, *b* yanlış alarm, *c* kaçırma ve *d* doğru ret sayısı olmak üzere kategorik skorlar şöyledir [24], [25]:

$$\mathrm{POD} = \frac{a}{a+c}, \mathrm{FAR} = \frac{b}{a+b}, \mathrm{CSI} = \frac{a}{a+b+c} \quad (2)$$

$$\mathrm{HSS} = \frac{2(ad-bc)}{(a+c)(c+d)+(a+b)(b+d)} \quad (3)$$

Burada Heidke beceri skoru (HSS), doğruluğu rastlantısal tahmine göre ölçmektedir [53], [54]. Olasılıksal tahminler, nadir olaylar için bilgilendirici olan kesinlik–duyarlılık eğrisi altındaki alan (PR-AUC) [55], [56], ROC eğrisi altındaki alan ve Brier skoru ile beceri skoru [57], [58] ile değerlendirilmektedir:

$$\mathrm{BS} = \frac{1}{N}\sum_{i=1}^{N}(p_i - o_i)^2, \mathrm{BSS} = 1 - \frac{\mathrm{BS}}{\mathrm{BS_{klim}}} \quad (4)$$

ILS kategorileri için sıralı olasılık skoru [59]

$$\mathrm{RPS} = \frac{1}{K-1}\sum_{k=1}^{K}(F_k - O_k)^2 \quad (5)$$

birikimli tahmin ve gözlem dağılımları F_k ve O_k (K=3) ile test kümesinde ortalaması alınarak ay–saat sınıf klimatolojisine göre bir beceri skoru (RPSS) olarak ifade edilmektedir. Yarım saatlik örnekler güçlü öz ilişki gösterdiğinden %95 güven aralıkları tüm günleri yeniden örnekleyen bir blok bootstrap ile elde edilmekte [60], [61], tahminler arasındaki farklar ise aynı günlerin eşleştirilmiş yeniden örneklemeleriyle (kategorik skorlar için 2000, PR-AUC ve BSS için 300 yineleme) sınanmaktadır.

H. Açıklanabilirlik

LightGBM modelleri, ağaçlar için TreeSHAP [23] ile tam olarak hesaplanan SHAP değerleriyle [22] açıklanmaktadır. Log-odds çıktısı $g(\mathbf{x})$ olan bir tahmin için katkılar φ_j yerel doğruluk özelliğini sağlar:

$$g(\mathbf{x}) = \phi_0 + \sum_{j=1}^{M}\phi_j \quad (6)$$

Burada φ_0 beklenen model çıktısı, φ_j ise *j* özniteliğinin Shapley değeridir [62]. Küresel önem, tüm sis durumlarını ve rastgele seçilmiş 6000 sissiz durumu içeren bir test örneğinde ortalama mutlak SHAP değeriyle özetlenmekte; bağımlılık grafikleri ise katkıları sisin fiziksel etkenleriyle ilişkilendirmektedir [21].

I. Erken Uyarı Uygulaması

Operasyonel sistem bir FastAPI web uygulamasıdır (Şekil 14). Uygulama her on dakikada bir son 120 saatin METAR'larını NOAA Aviation Weather Center'dan (yedek kaynak IEM) indirir; çevrimdışı çalışmayla tamamen aynı çözme, kalite kontrolü, ızgaralama ve öznitelik kodunu çalıştırır ve 1–6 saat için kalibre edilmiş sis olasılıklarını, 1, 3 ve 6 saat için ILS kategorisi görünümünü, bir uyarı seviyesini ve öne çıkan SHAP katkılarını yayımlar. TreeSHAP değerleri toplanabilir olduğundan 77 katkı, uzman olmayan kullanıcıların da okuyabilmesi için ayrıca on sade etken grubunda (ör. nem, rüzgâr, günün saati) toplanmaktadır. Sis gözleniyorsa veya 1–2 saatlik olasılık eşiğini aşıyorsa uyarı kırmızı, yalnızca 3–6 saatlik tahminler eşiklerini aşıyorsa turuncu, herhangi bir olasılık eşiğinin yarısını aşıyorsa sarıdır (izleme). Her tahmin kaydedilmekte ve geçerlilik zamanı geldiğinde otomatik olarak doğrulanmaktadır; böylece gerçek anlamda gerçek zamanlı bir doğrulama kaydı oluşmaktadır. Sunucu gerektirmeyen herkese açık bir kopya aynı döngüyü GitHub Actions üzerinde her 30 dakikada bir çalıştırmakta ve arayüzü https://atasakik.github.io/esenboga-fog-nowcasting/ adresinde yayımlamaktadır.

V. BULGULAR

A. Genel Başarım

Tablo IV, dört test sezonundaki tüm tahminlerin skorlarını vermektedir. 1 saatte tüm ML modelleri kalıcılık tahmininden açıkça daha başarılıdır; LightGBM en iyi CSI (0,729) ve HSS (0,842) değerlerine ve 0,739'luk bir Brier beceri skoruna ulaşırken kalıcılığın CSI değeri 0,652'dir. Fark öngörü süresiyle büyümektedir: 3 saatte en iyi CSI 0,472 (LSTM) iken kalıcılıkta 0,321, 6 saatte ise 0,340 (LSTM) iken 0,129'dur. Kalıcılık 3 ve 6 saatte klimatolojiden bile kötüleşirken (negatif BSS) tüm ML modelleri 6 saatte 0,26 ile 0,32 arasında BSS değerlerini korumaktadır. Çok sayıdaki kolay sissiz durum nedeniyle ROC alanları her modelde 0,98'in üzerindedir; bu yüzden Şekil 3'teki PR eğrileri daha bilgilendiricidir: 1 saatte altı model neredeyse ayırt

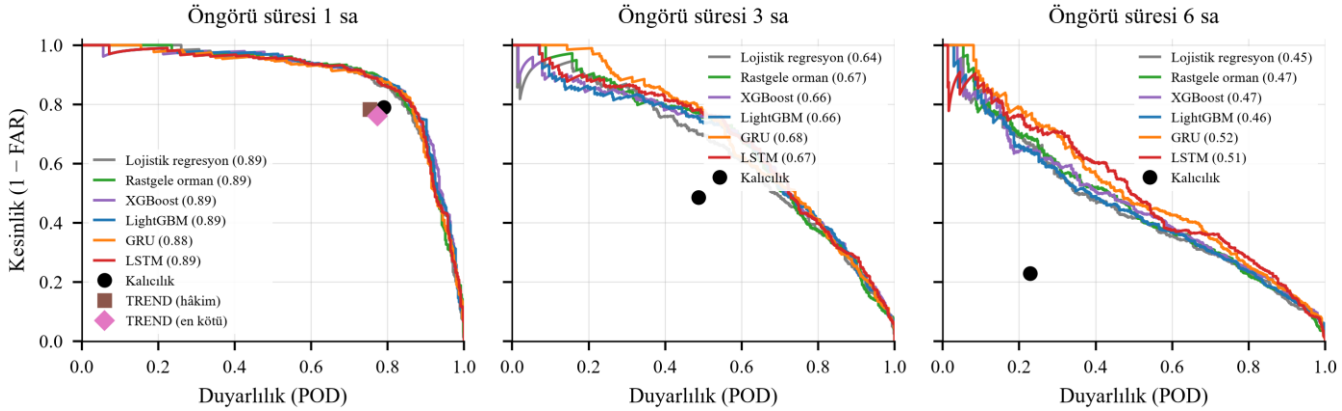
edilemezken 3 ve 6 saatte yinelemeli ağlar eğrinin büyük bölümüne hâkimdir ve en yüksek PR-AUC değerlerine ulaşır (GRU: 0,685 ve 0,517).

TABLO IV

SİS (GÖRÜŞ < 1000 M) TAHMİNLERİNİN 2022/23–2025/26 TEST SEZONLARINDA DOĞRULANMASI

Süre	Tahmin	PR-AUC	ROC-AUC	BS	BSS	POD	FAR	CSI	HSS
1 sa	Lojistik regresyon	0,885	0,997	0,0017	0,722	0,767	0,128	0,690	0,815
	Rastgele orman	0,889	0,997	**0,0016**	0,733	0,794	0,122	0,715	0,833
	XGBoost	**0,892**	**0,998**	**0,0016**	0,737	0,789	**0,120**	0,713	0,831
	LightGBM	0,891	**0,998**	**0,0016**	**0,739**	**0,825**	0,138	**0,729**	**0,842**
	GRU	0,882	**0,998**	0,0017	0,722	0,809	0,138	0,716	0,834
	LSTM	0,885	**0,998**	0,0017	0,725	0,789	0,135	0,703	0,824
	Kalıcılık	–	–	0,0027	0,563	0,789	0,211	0,652	0,788
	TREND (hâkim)	–	–	0,0029	0,529	0,753	0,217	0,623	0,767
	TREND (en kötü)	–	–	0,0030	0,512	0,774	0,240	0,622	0,765
3 sa	Lojistik regresyon	0,637	0,993	0,0035	0,425	0,529	0,328	0,421	0,590
	Rastgele orman	0,665	0,993	0,0034	0,455	0,574	0,279	0,470	0,637
	XGBoost	0,657	**0,994**	0,0034	0,455	0,531	**0,245**	0,453	0,622
	LightGBM	0,657	**0,994**	0,0034	0,455	0,585	0,302	0,467	0,634
	GRU	**0,685**	**0,994**	**0,0033**	0,462	0,543	0,255	0,457	0,626
	LSTM	0,673	**0,994**	**0,0033**	**0,463**	**0,612**	0,328	**0,472**	**0,639**
	Kalıcılık	–	–	0,0065	-0,063	0,487	0,513	0,321	0,483
6 sa	Lojistik regresyon	0,453	0,987	0,0045	0,264	0,496	0,584	0,292	0,449
	Rastgele orman	0,470	0,987	0,0044	0,277	0,480	0,536	0,309	0,468
	XGBoost	0,471	**0,989**	0,0044	0,281	0,473	0,530	0,308	0,468
	LightGBM	0,457	0,988	0,0045	0,270	**0,522**	0,592	0,297	0,454
	GRU	**0,517**	0,988	**0,0042**	**0,317**	0,352	**0,377**	0,290	0,447
	LSTM	0,509	0,988	**0,0042**	0,314	0,475	0,456	**0,340**	**0,504**
	Kalıcılık	–	–	0,0098	-0,598	0,229	0,771	0,129	0,224

BS: Brier skoru; BSS, eğitim döneminin ay–saat klimatolojisine göredir. Kategorik skorlar doğrulama kümesinde CSI'yı en büyükleyen eşikle hesaplanmıştır. Her öngörü süresindeki en iyi değer kalın yazılmıştır. TREND yalnızca 2 saate kadar tanımlıdır.



Şekil 3. Test sezonlarında sis tahminlerinin kesinlik–duyarlılık eğrileri (parantez içinde PR-AUC). İşaretler deterministik karşılaştırma tahminlerini göstermektedir.

Gün-blok bootstrap (Tablo V), iyileşmelerin sağlam olduğunu doğrulamaktadır: altı modelin her biri ile kalıcılık arasındaki eşleştirilmiş CSI ve HSS farkları üç öngörü süresinin tamamında anlamlı biçimde pozitiftir—örneğin LightGBM için ΔCSI 1 saatte 0,077 [0,052; 0,104], 3 saatte 0,146 [0,105; 0,188] ve 6 saatte 0,168 [0,099; 0,234]'tür. Beceri öngörü süresiyle düzgün biçimde azalmakta (Şekil 4), LightGBM'nin kalıcılığa göre göreli CSI kazancı 1 saatte %12'den 3 saatte %45'e ve 6 saatte %130'a yükselmektedir. İyileşme elverişli tek bir yıla da bağlı değildir: her model, dört test sezonunun her birinde ve her öngörü süresinde kalıcılıktan daha başarılıdır (Tablo VI).

TABLO V

%95 GÜN-BLOK BOOTSTRAP GÜVEN ARALIKLARI (TEST SEZONLARI)

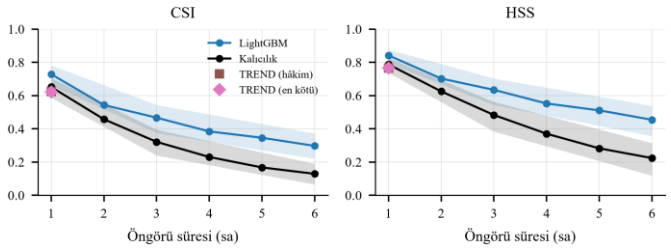
Süre	Tahmin	CSI	HSS	PR-AUC
1 sa	LightGBM	0,73* [0,66; 0,78]	0,84 [0,80; 0,88]	0,89 [0,84; 0,93]
	GRU	0,72* [0,65; 0,76]	0,83 [0,79; 0,87]	0,88 [0,83; 0,92]
	Kalıcılık	0,65 [0,59; 0,71]	0,79 [0,74; 0,83]	–
3 sa	LightGBM	0,47* [0,38; 0,54]	0,63 [0,54; 0,70]	0,66 [0,55; 0,74]
	GRU	0,46* [0,35; 0,54]	0,63 [0,52; 0,70]	0,68 [0,59; 0,76]
	Kalıcılık	0,32 [0,24; 0,39]	0,48 [0,38; 0,56]	–
6 sa	LightGBM	0,30* [0,22; 0,37]	0,45 [0,36; 0,54]	0,46 [0,34; 0,55]
	GRU	0,29* [0,19; 0,39]	0,45 [0,32; 0,55]	0,52 [0,40; 0,64]
	Kalıcılık	0,13 [0,07; 0,19]	0,22 [0,12; 0,31]	–

CSI kalıcılıktan anlamlı olarak yüksek (eşleştirilmiş bootstrap, günlerin 2000 yeniden örneklemesi)

TABLO VI

3 SA İÇİN SEZON BAZINDA BECERİ (TEST)

Sezon	Sis dilimi	CSI LightGBM	CSI GRU	CSI kalıcılık	PR-AUC LightGBM
2022/23	83	0,414	0,500	0,317	0,582
2023/24	94	0,432	0,362	0,253	0,587
2024/25	190	0,502	0,491	0,397	0,728
2025/26	79	0,486	0,452	0,244	0,659



Şekil 4. Test sezonlarında LightGBM ve kalıcılık tahminlerinin öngörü süresine göre CSI ve HSS değerleri ile 1 saatte METAR TREND tahmini. Gölgelendirme: 1, 3 ve 6 saatte hesaplanan %95 gün-blok bootstrap aralıkları (aradaki değerler enterpole edilmiştir).

B. Resmî TREND ve TAF Tahminleriyle Karşılaştırma

TREND tahmini her test METAR'ında mevcuttur. Aynı durumlar üzerinde (Tablo VII) TREND'in hâkim okuması 1 saatte CSI 0,623 ve HSS 0,767, en kötü durum okuması ise 0,622 ve 0,765 değerlerine ulaşmakta; bu değerler kalıcılığın (0,652 ve 0,788) biraz altındadır. Başka bir deyişle resmî 2 saatlik tahmin mevcut gözlemin ötesinde nadiren bilgi eklemektedir: TREND grupları çoğunlukla iyileşmeleri bildirmekte, yeni sis oluşumu ise nadiren öngörülmektedir. LightGBM TREND'i ΔCSI = 0,105 [0,075; 0,140] ve ΔHSS = 0,076 [0,053; 0,103] farkla geçmektedir; her iki fark da anlamlıdır. Çalışmanın yazıldığı sırada erişilebilen 30 günlük TAF penceresinde (29 Eylül–30 Ekim 2026; öngörü süresi başına yaklaşık 1 420 tahmin) sis gözlenmemiştir; ne TAF—her iki okumada da—ne de LightGBM sis tahmini vermiş, dolayısıyla ikisi de yanlış alarm üretmemiştir; en kötü durum TAF okuması ise durumların yaklaşık %8'inde 5 km'nin altında pus bildirmiştir. Sis sezonunu kapsayan bir TAF karşılaştırması bu nedenle canlı doğrulamaya bırakılmıştır.

TABLO VII

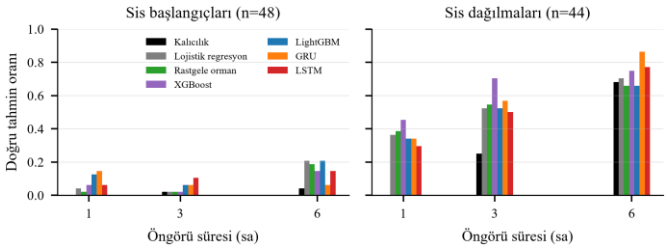
AYNI TEST ÖRNEKLERİNDE ML İLE METAR TREND TAHMİNİNİN KARŞILAŞTIRILMASI

Süre	Tahmin	POD	FAR	CSI	HSS
1 sa	LightGBM	**0,825**	**0,138**	**0,729**	**0,842**
	GRU	0,809	**0,138**	0,716	0,834
	Kalıcılık	0,789	0,211	0,652	0,788
	TREND (hâkim)	0,753	0,217	0,623	0,767
	TREND (en kötü)	0,774	0,240	0,622	0,765

Çözümlenebilir TREND içeren 70 037 tahmin (1 sa için 446 sis durumu).

C. Sis Başlangıçları ve Dağılmaları

Başlangıç ve dağılmalar, kalıcılık tahmini ikisini de öngöremediği için kısa vadeli tahminin operasyonel değer yarattığı anlardır. Şekil 5, test sezonlarındaki 48 sis başlangıcının (en az 2 saat sissiz geçen sürenin ardından sis) ve 44 dağılmanın doğru tahmin edilme oranını göstermektedir. Dağılmalar iyi yakalanmaktadır: 1 saatte XGBoost dağılmaların %45'ini doğru tahmin etmekte (kalıcılık: %0), 6 saatte GRU %86'ya ulaşmaktadır (kalıcılık: %68). Başlangıçlar ise en zor problem olmaya devam etmektedir: CSI'yı en büyükleyen eşiklerde modeller başlangıçların %2–21'ini yakalarken kalıcılıkta bu oran %0–4'tür. Kademeli uyarı tasarımı bu sınırlılığı hafifletmektedir: izleme seviyesinde (τ_h/2) LightGBM, başlangıçların 1, 3 ve 6 saat önceden sırasıyla %25, %21 ve %38'ini işaretlerken CSI yalnızca 0,729'dan 0,692'ye, 0,467'den 0,435'e ve 0,297'den 0,271'e düşmektedir.



Şekil 5. CSI'yı en büyükleyen eşiklerde test sezonlarındaki sis başlangıçlarının (solda) ve dağılmalarının (sağda) doğru tahmin edilme oranı.

D. ILS Kategorisi Tahminleri

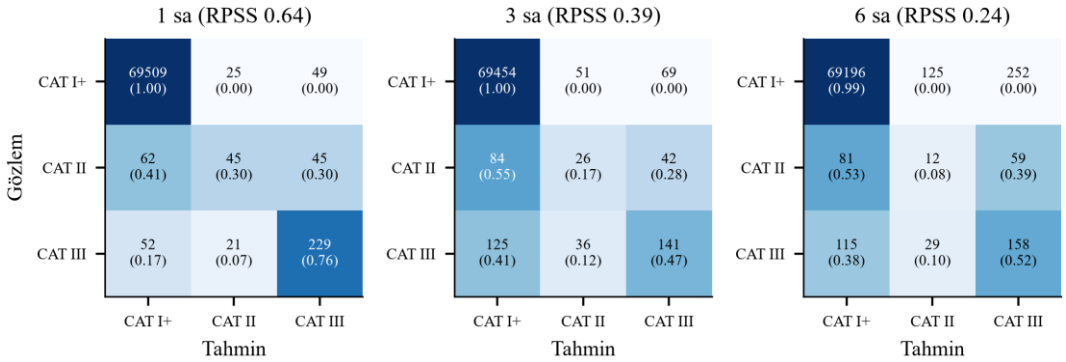
Tablo VIII ve Şekil 6 sıralı RVR tahminlerini özetlemektedir. Tüm ML modelleri her öngörü süresinde pozitif bir sıralı olasılık beceri skoruna ulaşmaktadır—1 saatte 0,636 (LightGBM), 3 saatte 0,407 (XGBoost) ve 6 saatte 0,281 (LSTM)—buna karşılık kalıcılık 0,427'den −0,166'ya ve −0,695'e düşmektedir. CAT III koşulları (RVR < 350 m) için LightGBM 1 saatte CSI 0,578'e, GRU ise 3 saatte 0,371'e ulaşmaktadır (kalıcılık: 0,521 ve 0,225). Karışıklık matrisleri CAT III'ün iyi tanındığını (1 saatte durumların %76'sı), ara sınıf olan CAT II'nin ise komşu sınıflarla sık karıştırılan en zor sınıf olduğunu göstermektedir; bu, RVR'nin dar bir geçiş bandı için beklenen bir durumdur.

TABLO VIII

TEST SEZONLARINDA ILS KATEGORİSİ (RVR) TAHMİNLERİ

Süre	Tahmin	RPSS	Macro-F1	HSS_3	$CSI_{\geq II}$	CSI_{III}
1 sa	LR	0,596	0,602	0,656	0,632	0,514
	RO	0,629	0,653	0,680	0,644	0,561
	XGBoost	0,632	0,670	0,683	0,639	0,563
	LightGBM	**0,636**	**0,701**	**0,706**	0,644	**0,578**
	GRU	0,608	0,618	0,677	0,650	0,515
	LSTM	0,620	0,629	0,680	**0,660**	0,532
	Kalıcılık	0,427	0,673	0,657	0,599	0,521
3 sa	LR	0,345	0,525	0,468	0,407	0,311
	RO	0,393	0,550	0,508	0,434	0,352
	XGBoost	**0,407**	**0,573**	0,502	0,446	0,343
	LightGBM	0,393	0,568	0,501	0,427	0,341
	GRU	0,403	0,527	**0,526**	**0,451**	**0,371**
	LSTM	0,393	0,552	0,494	0,446	0,319
	Kalıcılık	-0,166	0,512	0,390	0,320	0,225
6 sa	LR	0,215	0,467	0,388	0,293	0,245
	RO	0,241	0,511	0,392	0,299	0,268
	XGBoost	0,235	**0,515**	0,393	0,317	0,272
	LightGBM	0,237	0,494	0,389	0,310	0,258
	GRU	0,267	0,478	0,430	0,335	0,270
	LSTM	**0,281**	0,489	**0,440**	**0,341**	**0,297**
	Kalıcılık	-0,695	0,405	0,162	0,120	0,073

RPSS, ay–saat sınıf klimatolojisine görelidir; HSS_3: üç kategorili Heidke skoru. $CSI_{\geq II}$: RVR < 550 m (CAT II veya daha kötü); CSI_{III}: RVR < 350 m. LR: lojistik regresyon; RO: rastgele orman.



Şekil 6. Test sezonlarında LightGBM ILS kategorisi tahminlerinin karışıklık matrisleri (sayılar ve satır bazında normalleştirilmiş oranlar).

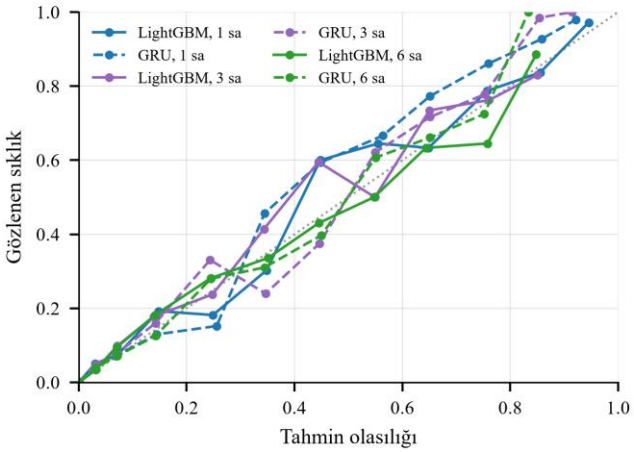
E. Sınıf Dengesizliği ve Kalibrasyon

Dengesizlik deneyi (Tablo IX), sınıf ağırlıklandırma, SMOTE ve alt örneklemenin sıralama kalitesini güvenilir biçimde iyileştirmediğini—LR'de doğrulama PR-AUC değerini 0,759'dan 0,720–0,747'ye düşürdüğünü—ancak ham olasılıkları ciddi biçimde bozduğunu göstermektedir: sınıf ağırlıklandırma LR'nin doğrulama Brier skorunu on kat artırmaktadır (0,0026'dan 0,0261'e). Yeniden kalibrasyon bu bozulmanın büyük bölümünü gidermekle birlikte en basit seçenek olan örnekleme yapmadan kalibrasyon, alternatifleri kadar veya onlardan daha iyidir; bu nedenle tüm nihai modellerde bu seçenek kullanılmıştır. Kalibre edilmiş tahminlerin güvenilirlik eğrileri tüm öngörü sürelerinde köşegeni yakından izlemektedir (Şekil 7). Bu sonuç önemsiz değildir: test sezonlarındaki sis sıklığı (%0,64) eğitim döneminin (%1,24) yalnızca yarısıdır ve en güncel sezonlarda yapılan kalibrasyon olasılıkları bu değişime uyarlamıştır.

TABLO IX
SINIF DENGESİZLİĞİ STRATEJİLERİ (SİS, 3 SA)

Model	Strateji	PR-AUC$_v$	BS$_v$ ham	BS$_v$ kal.	PR-AUC$_t$	CSI$_t$
Lojistik regresyon	yok	0,759	0,0026	0,0026	0,636	0,395
	sınıf ağırlığı	0,720	0,0261	0,0028	0,594	0,406
	SMOTE	0,736	0,0101	0,0027	0,614	0,408
	alt örnekleme	0,747	0,0056	0,0026	0,619	0,405
LightGBM	yok	0,741	0,0026	0,0026	0,632	0,457
	sınıf ağırlığı	0,743	0,0056	0,0025	0,638	0,462
	SMOTE	0,754	0,0027	0,0026	0,661	0,443
	alt örnekleme	0,764	0,0047	0,0024	0,632	0,446

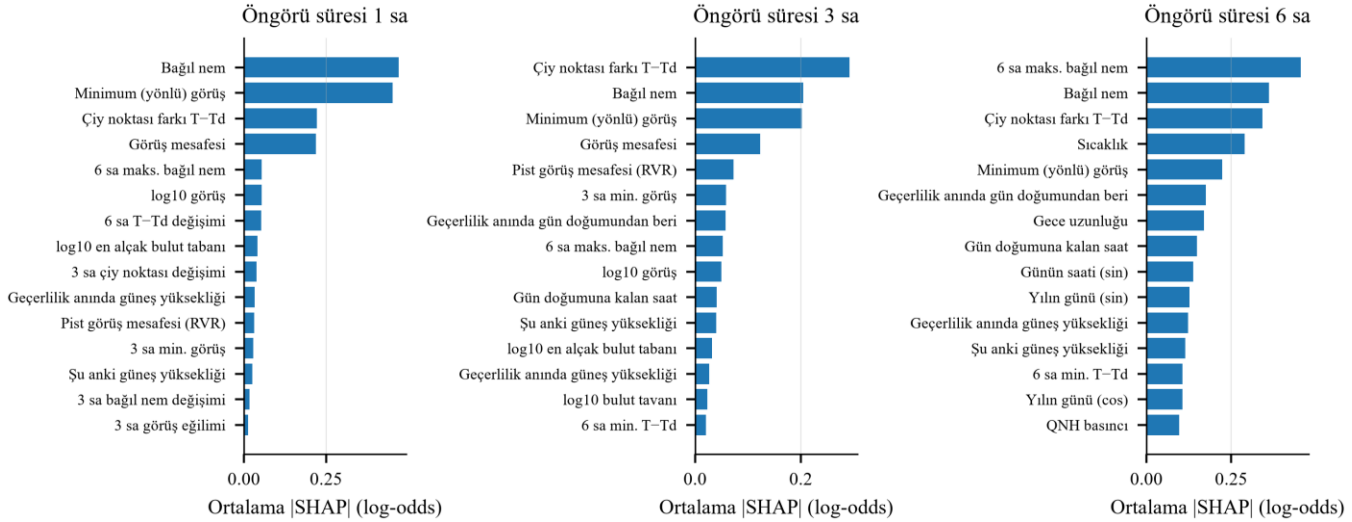
v: doğrulama, t: test. Kalibrasyon (yok/Platt/izotonik) bir-sezon-dışarıda çapraz doğrulamayla seçilmiştir.



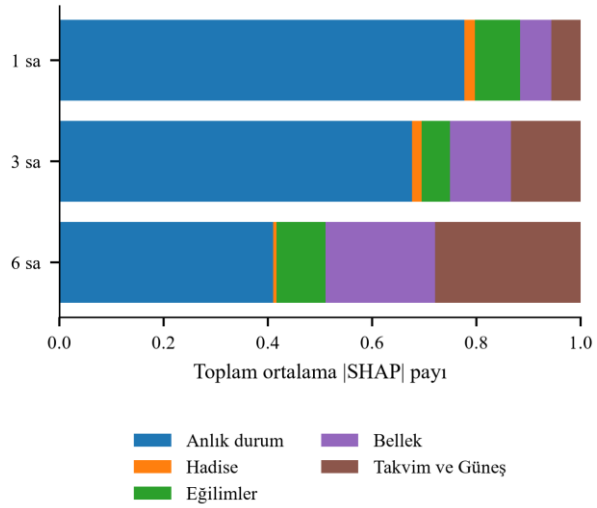
Şekil 7. Test sezonlarında kalibre edilmiş LightGBM (düz çizgi) ve GRU (kesikli çizgi) sis tahminlerinin güvenilirlik diyagramı; 15'ten az tahmin içeren aralıklar gösterilmemiştir.

F. Açıklanabilirlik

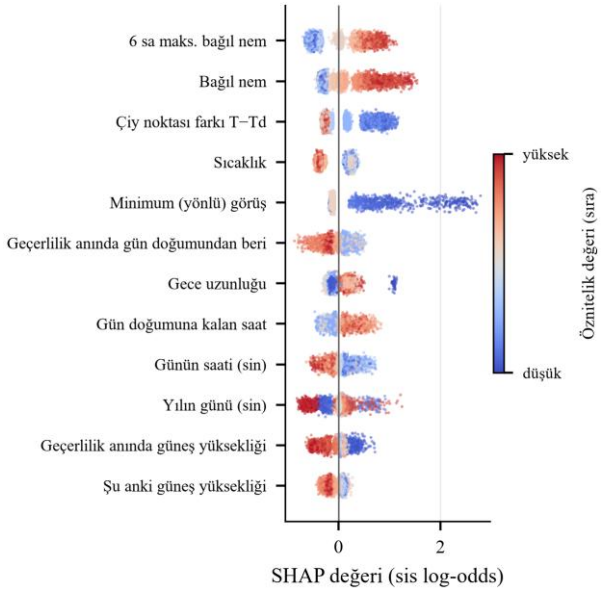
SHAP analizi fiziksel olarak tutarlı bir tablo ortaya koymaktadır. 1 saatte tahmin anlık duruma—bağıl nem, minimum ve hâkim görüş ile çiy noktası farkı (Şekil 8)—hâkimdir ve bu grup toplam katkının %78'ini taşımaktadır (Şekil 9). Öngörü süresi arttıkça anlık durumun payı 6 saatte %41'e düşerken astronomik ve takvim terimlerinin payı %6'dan %28'e, sınır tabaka belleğinin payı ise %6'dan %21'e yükselmektedir.



Şekil 8. 1, 3 ve 6 saatlik LightGBM sis modellerinde en önemli on beş özniteliğin ortalama mutlak SHAP değerleri.



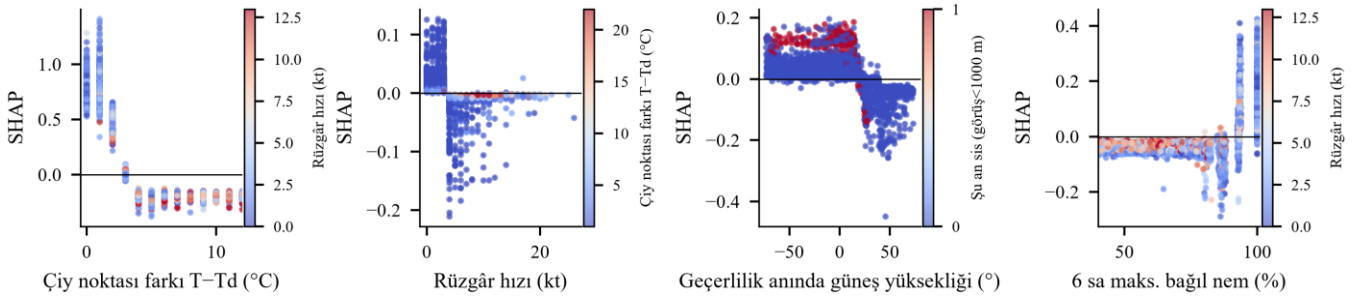
Şekil 9. Öznitelik grubu ve öngörü süresine göre toplam ortalama mutlak SHAP değerinin payı.



Şekil 10. 6 saatlik modelde en önemli on iki özniteliğin SHAP değerleri; renk, öznitelik değerinin yüzdelik sırasını göstermektedir.

6 saatte sıralamanın başında 6 saatlik maksimum bağıl nem, bağıl nem, çiy noktası farkı ve sıcaklık yer almakta; bunları geçerlilik zamanında gün doğumundan bu yana geçen süre, gece uzunluğu ve gün doğumuna kalan süre izlemektedir (Şekil 10): yüksek nem, küçük çiy noktası farkı, düşük sıcaklık ve uzun geceler tahmini sise doğru iterken gün doğumundan sonraki geçerlilik zamanları tahmini sisten uzaklaştırmaktadır—bu, radyasyon sisinin tipik imzasıdır.

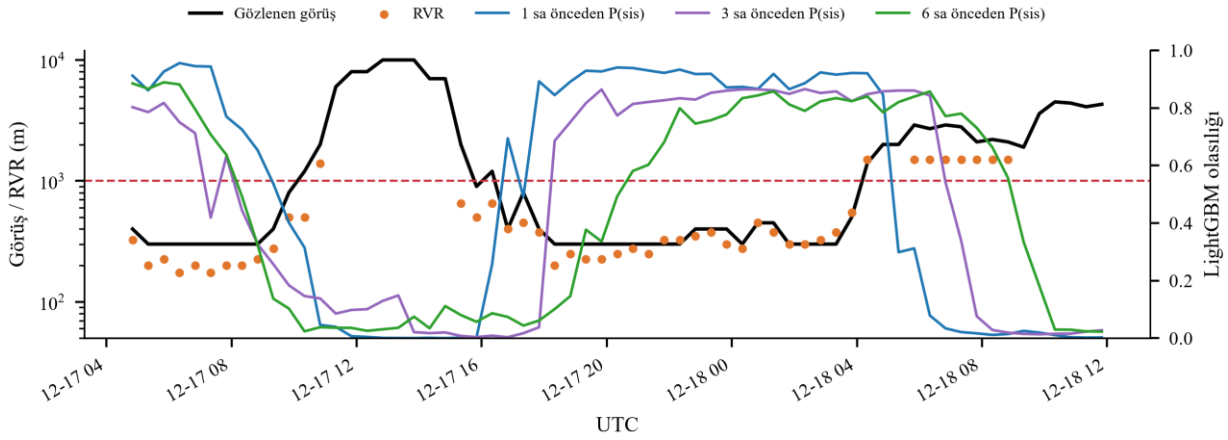
Bağımlılık grafikleri (Şekil 11) ders kitabı düzeyindeki sis fiziğini yeniden üretmektedir: 2 °C veya daha küçük çiy noktası farkları log-odds değerini +1,4'e kadar artırırken 4 °C ve üzerindeki farklar azaltmaktadır; sakin ve hafif rüzgârlar (≤ 3 kt) sisi desteklerken 4–10 kt'lık rüzgârlar mekanik karışımla sisi bastırmaktadır; yaklaşık %93'ün üzerindeki 6 saatlik maksimum bağıl nem sisi güçlü biçimde desteklemektedir; geçerlilik zamanında Güneş ufkun yaklaşık 15° üzerine çıktığında ise katkı negatife dönmekte ve Güneş ısıtmasıyla dağılmayı yansıtmaktadır.



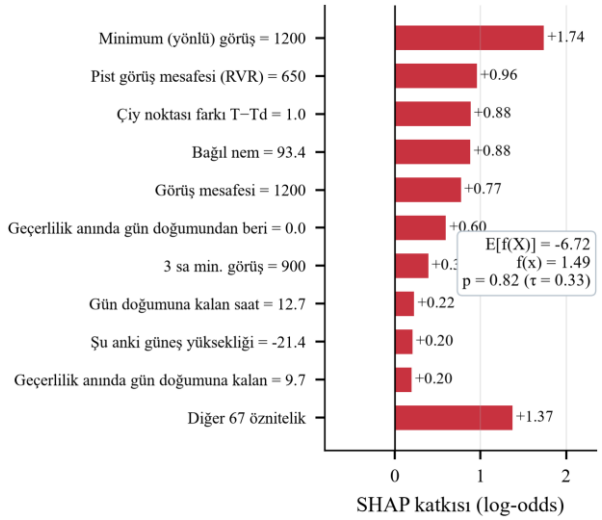
Şekil 11. 3 saatlik sis modelinin çiy noktası farkı, rüzgâr hızı, geçerlilik zamanındaki Güneş yükseklik açısı ve 6 saatlik maksimum bağıl neme göre SHAP bağımlılığı; renk etkileşen bir değişkeni göstermektedir.

G. Olay İncelemesi: 17–18 Aralık 2022

Şekil 12, test döneminden iki aşamalı bir olayı göstermektedir. Sis 17 Aralık'ta yaklaşık 10 UTC'ye kadar sürmüş, öğleden sonra açılmış ve 16:50 UTC'de yeniden oluşarak RVR çoğunlukla 200–400 m arasında kalmak üzere 18 Aralık 03:50 UTC'ye kadar devam etmiştir. Görüşün henüz 1200 m olduğu 16:20 UTC'de 3 saatlik model 0,82 sis olasılığı (eşik 0,33), yani yeniden oluşum için doğru bir uyarı vermiştir. Bu tahminin SHAP açıklaması (Şekil 13) tahmini düşen minimum görüşe (+1,74), 650 m'lik RVR'ye (+0,96), 1 °C'lik çiy noktası farkına (+0,88) ve %93'lük bağıl neme (+0,88) dayandırmaktadır—deneyimli bir tahmincinin kullanacağı ipuçlarının tam olarak aynısı. 1 saatlik tahminler olayı yakından izlemekte, 3 ve 6 saatlik tahminler akşam saatlerinde olasılığı yükseltip sisin gece boyunca süreceğini öngörmektedir; gün doğumundan sonra tüm öngörü süreleri dağılmayı doğru tahmin etmekte, uzun öngörü süreleri ise daha geç tepki vermektedir.



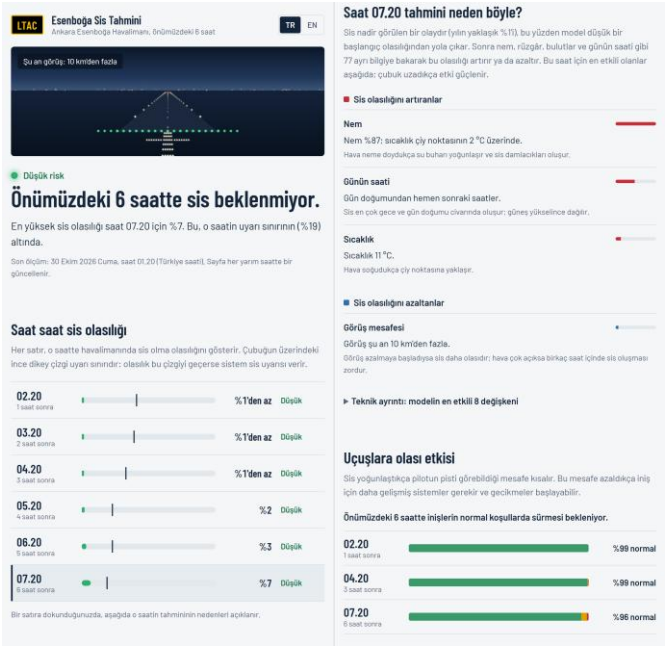
Şekil 12. 17–18 Aralık 2022'de LTAC'de gözlenen görüş ve RVR ile her geçerlilik zamanından 1, 3 ve 6 saat önce verilen LightGBM sis olasılıkları.



Şekil 13. 17 Aralık 2022 16:20 UTC'de verilen 3 saatlik tahminin SHAP açıklaması (görüş 1200 m; sis 30 dakika sonra oluştu).

H. Operasyonel Başarım

Hizmete alınan uygulama (Şekil 14) iki yolla doğrulanmıştır. İlk olarak test kümesi sonrasındaki operasyonel dönem (Temmuz–Ekim 2026) web uygulamasının koduyla yeniden oynatılmış ve öngörü süresi başına 5 727–5 737 tahmin elde edilmiştir (Tablo X); bu sıcak sezon döneminde sis oluşmamış ve sistem hiçbir öngörü süresinde sis uyarısı vermemiştir, yani hiç yanlış alarm üretmemiştir. İkinci olarak, canlı sistemin yaptığı gibi öznitelikleri yalnızca önceki 120 saatin rasatlarından 40 rastgele zamanda yeniden hesaplayan bir eşdeğerlik testi, toplu (batch) olasılıkları makine hassasiyetinde yeniden üretmiştir (240 karşılaştırmada en büyük fark 0,0). Canlı kayıt 29 Ekim 2026'da, 2026/27 sis sezonunun başında başlamıştır ve otomatik olarak doğrulanan kayıt dönem boyunca sürekli güncellenmektedir.



Şekil 14. Web tabanlı erken uyarı uygulaması. Solda: gözlenen görüşe göre çizilen pist sahnesi üzerinde sade dille durum özeti ve önümüzdeki 6 saatin sis olasılıkları ile uyarı eşikleri. Sağda: seçilen saatin etkili faktörleri (sade dildeki gruplara toplanmış SHAP değerleri) ve ILS kategorisi görünümü.

TABLO X
TEST DÖNEMİ SONRASI OPERASYONEL DOĞRULAMA

Dönem	Süre	n	Sis	Uyarı	POD	FAR	BS
07/2026–10/2026 yeniden oynatma	1 sa	5 737	0	0	–	–	0,0000
07/2026–10/2026 yeniden oynatma	2 sa	5 735	0	0	–	–	0,0000
07/2026–10/2026 yeniden oynatma	3 sa	5 734	0	0	–	–	0,0000
07/2026–10/2026 yeniden oynatma	4 sa	5 731	0	0	–	–	0,0000
07/2026–10/2026 yeniden oynatma	5 sa	5 729	0	0	–	–	0,0000
07/2026–10/2026 yeniden oynatma	6 sa	5 727	0	0	–	–	0,0000

Yeniden oynatma: arşiv METAR'ları web uygulamasının koduyla işlenmiştir; canlı: çalışan uygulamanın kaydettiği ve otomatik doğruladığı tahminler.

VI. TARTIŞMA

Bulgular, yalnızca gözleme dayalı bir kısa vadeli tahminin Esenboğa'da hem kalıcılık tahminine hem de resmî TREND tahminine önemli ölçüde beceri katabildiğini göstermektedir. Üç nokta özellikle vurgulanmalıdır. Birincisi, en iyi model öngörü süresine bağlıdır: 1 saatte anlık durumdaki keskin eşiklerden yararlanan ağaç toplulukları en iyiyken 3–6 saatte yinelemeli ağlar 12 saatlik geçmişten daha fazla bilgi çıkarmakta ve en iyi olasılıksal skorlara ulaşmaktadır. Operasyonel bir sistem bu nedenle en kısa sürelerde artırma yöntemlerini, 2 saatin ötesinde yinelemeli ağları birleştirebilir. İkincisi, SHAP analizi modellerin rastlantısal ilişkiler yerine radyasyon sisinin fiziğini—doygunluk, zayıf karışım ve günlük ışınım döngüsü—öğrendiğini doğrulamaktadır; bu, tahmincilerin güvenini desteklemekte [21] ve LTAC'de radyasyon sisinin baskınlığıyla uyumludur [4]. Üçüncüsü, TREND ile karşılaştırma resmî 2 saatlik tahminin esasen kalıcılık olduğunu, dolayısıyla mütevazı bir veriye dayalı kılavuzun bile çok kısa vadeli hizmeti iyileştirebileceğini göstermektedir.

Çalışmanın sınırlılıkları da bulunmaktadır. Yalnızca nokta gözlemleri kullanılmıştır; tek bir METAR'da görülemeyen sınır tabaka süreçlerine ve adveksiyona bağlı olan sis başlangıçlarını tahmin etmek zor olmaya devam etmektedir ve sayısal hava tahmini, uydu veya tavan ölçer (seilometre) verileri bu konuda büyük olasılıkla iyileşme sağlayacaktır [11], [19]. Test sezonları için tarihsel TAF arşivine erişilemediğinden TAF karşılaştırması kısa ve sissiz bir pencereyle sınırlı kalmıştır; bu karşılaştırma canlı doğrulamayla tamamlanacaktır. Yalnızca tek bir havalimanı incelendiğinden aktarılabilirlik değerlendirilmemiştir [20]. Son olarak sis sıklığının 21 yıl boyunca azalması durağan olmayan bir süreci işaret etmektedir; sezonlarla hizalı doğrulama ve güncel sezonlarda kalibrasyon bu etkiyi azaltmış olsa da modellerin dönemsel olarak yeniden eğitilmesi gerekecektir.

VII. SONUÇ

Bu makalede Ankara Esenboğa Havalimanı'nda sis ve düşük görüş için ilk makine öğrenmesi tabanlı kısa vadeli tahmin sistemi sunulmuştur. Kalite kontrolünden geçirilmiş 21,8 yıllık METAR/SPECI rasatlarına dayanan ve dört bağımsız sis sezonunda doğrulanan tüm modeller kalıcılık tahmininden anlamlı biçimde daha başarılı olmuş, LightGBM ise 1 saatte resmî METAR TREND tahminini CSI'da 0,105 farkla geçmiştir. Kalibre edilmiş olasılıklar, ILS kategorisi tahminleri ve SHAP açıklamaları tahminleri operasyonel olarak yorumlanabilir kılmakta; açık kaynaklı web uygulaması ise bunları sürekli öz doğrulamayla gerçek zamanlı olarak sunmaktadır. Gelecek çalışmalarda başlangıç tespitini iyileştirmek için sayısal model ve uydu öznitelikleri eklenecek, TAF karşılaştırması tam sis sezonlarına genişletilecek ve yaklaşım diğer Türk havalimanlarına aktarılacaktır.

EK

Doğrulama sezonlarında seçilen hiperparametreler Tablo XI'de listelenmiştir. Veri setinin tamamı, çözücü, eğitim ve değerlendirme betikleri, eğitilmiş modeller, İngilizce ve Türkçe şekiller ve web uygulaması https://github.com/AtaSakik/esenboga-fog-nowcasting adresindedir; tek bir betik bu makaledeki tüm sayıları yeniden üretmektedir.

TABLO XI
SEÇİLEN HİPERPARAMETRELER

Model	Süre	Ayar
LightGBM	1 sa	η=0,026, leaves=17, min_child=42, ff=0,76, bf=0,71, λ_2=0,0383
LightGBM	2 sa	η=0,027, leaves=119, min_child=203, ff=0,96, bf=0,95, λ_2=0,475
LightGBM	3 sa	η=0,025, leaves=27, min_child=59, ff=0,67, bf=0,89, λ_2=0,00783
LightGBM	4 sa	η=0,052, leaves=16, min_child=122, ff=0,50, bf=0,53, λ_2=17,7
LightGBM	5 sa	η=0,052, leaves=16, min_child=122, ff=0,50, bf=0,53, λ_2=17,7
LightGBM	6 sa	η=0,053, leaves=15, min_child=316, ff=0,69, bf=0,69, λ_2=14

XGBoost	1 sa	η=0,032, depth=5, mcw=2,0, subsample=0,70, colsample=0,74, λ=0,447
XGBoost	3 sa	η=0,035, depth=9, mcw=14,8, subsample=1,00, colsample=0,70, λ=0,574
XGBoost	6 sa	η=0,084, depth=6, mcw=8,1, subsample=0,60, colsample=0,45, λ=27,7
GRU	1/3/6	hidden=32, layers=2, dropout=0,2, lr=0,001, wd=0,0001, seq=24×30 min
LSTM	1/3/6	hidden=64, layers=2, dropout=0,2, lr=0,001, wd=0,0001, seq=24×30 min

TEŞEKKÜR

Yazar, meteorolojik arşivlerini açık erişime sunan Iowa Environmental Mesonet, Ogimet ve NOAA Aviation Weather Center'a ve proje süresince verdiği rehberlik için YMH453 Makine Öğrenmesi dersinin öğretim üyesine teşekkür eder.

KAYNAKLAR

[1] I. Gultepe et al., "Fog research: A review of past achievements and future perspectives," *Pure Appl. Geophys.*, vol. 164, no. 6–7, pp. 1121–1159, Jun. 2007, doi: 10.1007/s00024-007-0211-x.

[2] M. Haeffelin et al., "PARISFOG: Shedding new light on fog physical processes," *Bull. Amer. Meteorol. Soc.*, vol. 91, no. 6, pp. 767–783, Jun. 2010, doi: 10.1175/2009BAMS2671.1.

[3] R. Dalmau and J. Attia, "A collection of machine learning models for improved airport operations amidst adverse weather conditions," *Eur. J. Transp. Infrastruct. Res.*, vol. 25, no. 1, pp. 133–159, Feb. 2025, doi: 10.59490/ejtir.2025.25.1.7487.

[4] G. Çamalan, S. Yağan ve N. Akgün, "Esenboğa Havalimanı sis etüdü," *I. Meteoroloji Sempozyumu*, Ankara, Türkiye, Mayıs 2010. [Çevrimiçi]. Erişim: https://www.mgm.gov.tr/FILES/genel/makale/sisbildirisi.pdf

[5] R. Koyuncu, A. Deniz, and E. T. Özdemir, "Ankara Esenboğa International Airport (Turkey) fog analysis and synoptical investigation of the fog event dated 17–19 December 2019," *Int. J. Climatol.*, vol. 42, no. 16, pp. 8368–8389, Dec. 2022, doi: 10.1002/joc.7728.

[6] P. Kneringer, S. J. Dietz, G. J. Mayr, and A. Zeileis, "Probabilistic nowcasting of low-visibility procedure states at Vienna International Airport during cold season," *Pure Appl. Geophys.*, vol. 176, no. 5, pp. 2165–2177, May 2019, doi: 10.1007/s00024-018-1863-4.

[7] S. J. Dietz, P. Kneringer, G. J. Mayr, and A. Zeileis, "Forecasting low-visibility procedure states with tree-based statistical methods," *Pure Appl. Geophys.*, vol. 176, no. 6, pp. 2631–2644, Jun. 2019, doi: 10.1007/s00024-018-1914-x.

[8] S. J. Dietz, P. Kneringer, G. J. Mayr, and A. Zeileis, "Low-visibility forecasts for different flight planning horizons using tree-based boosting models," *Adv. Stat. Climatol. Meteorol. Oceanogr.*, vol. 5, no. 1, pp. 101–114, Jun. 2019, doi: 10.5194/ascmo-5-101-2019.

[9] D. Alves, M. Belo-Pereira, F. Mendonça, and F. Morgado-Dias, "Intelligent visibility forecasting at airports: A systematic review," *Environ. Res. Commun.*, vol. 7, no. 6, Art. no. 062002, Jun. 2025, doi: 10.1088/2515-7620/addea9.

[10] S. Salcedo-Sanz, D. Guijo-Rubio, J. Pérez-Aracil, C. Peláez-Rodríguez, A. M. Gomez-Orellana, and P. A. Gutiérrez-Peña, "Artificial intelligence-based methods and algorithms in fog and atmospheric low-visibility forecasting," *Atmosphere*, vol. 16, no. 9, Art. no. 1073, Sep. 2025, doi: 10.3390/atmos16091073.

[11] G. R. Herman and R. S. Schumacher, "Using reforecasts to improve forecasting of fog and visibility for aviation," *Weather Forecast.*, vol. 31, no. 2, pp. 467–482, Apr. 2016, doi: 10.1175/WAF-D-15-0108.1.

[12] D. Fabbian, R. de Dear, and S. Lellyett, "Application of artificial neural network forecasts to predict fog at Canberra International Airport," *Weather Forecast.*, vol. 22, no. 2, pp. 372–381, Apr. 2007, doi: 10.1175/WAF980.1.

[13] C. Marzban, S. Leyton, and B. Colman, "Ceiling and visibility forecasts via neural networks," *Weather Forecast.*, vol. 22, no. 3, pp. 466–479, Jun. 2007, doi: 10.1175/WAF994.1.

[14] J. B. Bremnes and S. C. Michaelides, "Probabilistic visibility forecasting using neural networks," *Pure Appl. Geophys.*, vol. 164, no. 6–7, pp. 1365–1381, Jun. 2007, doi: 10.1007/s00024-007-0223-6.

[15] D. Guijo-Rubio, P. A. Gutiérrez, C. Casanova-Mateo, J. Sanz-Justo, S. Salcedo-Sanz, and C. Hervás-Martínez, "Prediction of low-visibility events due to fog using ordinal classification," *Atmos. Res.*, vol. 214, pp. 64–73, Dec. 2018, doi: 10.1016/j.atmosres.2018.07.017.

[16] C. Castillo-Botón et al., "Machine learning regression and classification methods for fog events prediction," *Atmos. Res.*, vol. 272, Art. no. 106157, Jul. 2022, doi: 10.1016/j.atmosres.2022.106157.

[17] L. Zhu, G. Zhu, L. Han, and N. Wang, "The application of deep learning in airport visibility forecast," *Atmos. Clim. Sci.*, vol. 7, no. 3, pp. 314–322, 2017, doi: 10.4236/acs.2017.73023.

[18] L. C. Ortega, L. D. Otero, M. Solomon, C. E. Otero, and A. Fabregas, "Deep learning models for visibility forecasting using climatological data," *Int. J. Forecast.*, vol. 39, no. 2, pp. 992–1004, Apr. 2023, doi: 10.1016/j.ijforecast.2022.03.009.

[19] H. Kamangir et al., "FogNet: A multiscale 3D CNN with double-branch dense block and attention mechanism for fog prediction," *Mach. Learn. Appl.*, vol. 5, Art. no. 100038, Sep. 2021, doi: 10.1016/j.mlwa.2021.100038.

[20] M. Cerda Castillo, "Geographic transferability of machine learning models for short-term airport fog forecasting," 2025, arXiv:2510.21819.

[21] A. McGovern et al., "Making the black box more transparent: Understanding the physical implications of machine learning," *Bull. Amer. Meteorol. Soc.*, vol. 100, no. 11, pp. 2175–2199, Nov. 2019, doi: 10.1175/BAMS-D-18-0195.1.

[22] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, Long Beach, CA, USA, 2017, pp. 4765–4774.

[23] S. M. Lundberg et al., "From local explanations to global understanding with explainable AI for trees," *Nat. Mach. Intell.*, vol. 2, no. 1, pp. 56–67, Jan. 2020, doi: 10.1038/s42256-019-0138-9.

[24] I. T. Jolliffe and D. B. Stephenson, Eds., *Forecast Verification: A Practitioner's Guide in Atmospheric Science*, 2nd ed. Chichester, U.K.: Wiley, 2012, doi: 10.1002/9781119960003.

[25] D. S. Wilks, *Statistical Methods in the Atmospheric Sciences*, 4th ed. Amsterdam, The Netherlands: Elsevier, 2019, doi: 10.1016/C2017-0-03921-6.

[26] G. Mahringer, "Terminal aerodrome forecast verification in Austro Control using time windows and ranges of forecast conditions," *Meteorol. Appl.*, vol. 15, no. 1, pp. 113–123, Mar. 2008, doi: 10.1002/met.62.

[27] Iowa Environmental Mesonet, "ASOS-AWOS-METAR data download," Iowa State Univ., Ames, IA, ABD. [Çevrimiçi]. Erişim: https://mesonet.agron.iastate.edu/request/download.phtml (erişim tarihi 29 Ekim 2026).

[28] G. Ballester Valor, "Ogimet: METAR, SPECI ve TAF arşivi." [Çevrimiçi]. Erişim: https://www.ogimet.com (erişim tarihi 29 Ekim 2026).

[29] NOAA Aviation Weather Center, "Data API." [Çevrimiçi]. Erişim: https://aviationweather.gov/data/api/ (erişim tarihi 29 Ekim 2026).

[30] *Manual on Codes—International Codes, Volume I.1, Part A: Alphanumeric Codes*, WMO-No. 306, World Meteorological Organization, Geneva, Switzerland, 2019.

[31] *Meteorological Service for International Air Navigation, Annex 3 to the Convention on International Civil Aviation*, 20th ed., International Civil Aviation Organization, Montréal, QC, Canada, 2018.

[32] *Manual of All-Weather Operations*, Doc 9365-AN/910, 4th ed., International Civil Aviation Organization, Montréal, QC, Canada, 2017.

[33] *Manual of Runway Visual Range Observing and Reporting Practices*, Doc 9328-AN/908, 3rd ed., International Civil Aviation Organization, Montréal, QC, Canada, 2005.

[34] E. Frank and M. Hall, "A simple approach to ordinal classification," in *Machine Learning: ECML 2001* (Lecture Notes in Computer Science, vol. 2167). Berlin, Germany: Springer, 2001, pp. 145–156, doi: 10.1007/3-540-44795-4_13.

[35] O. A. Alduchov and R. E. Eskridge, "Improved Magnus form approximation of saturation vapor pressure," *J. Appl. Meteorol.*, vol. 35, no. 4, pp. 601–609, Apr. 1996, doi: 10.1175/1520-0450(1996)035<0601:IMFAOS>2.0.CO;2.

[36] J. W. Spencer, "Fourier series representation of the position of the sun," *Search*, vol. 2, no. 5, p. 172, 1971.

[37] D. R. Cox, "The regression analysis of binary sequences," *J. R. Stat. Soc. Ser. B*, vol. 20, no. 2, pp. 215–232, Jul. 1958, doi: 10.1111/j.2517-6161.1958.tb00292.x.

[38] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/A:1010933404324.

[39] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, San Francisco, CA, USA, Aug. 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[40] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, Long Beach, CA, USA, 2017, pp. 3146–3154.

[41] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, Anchorage, AK, USA, Jul. 2019, pp. 2623–2631, doi: 10.1145/3292500.3330701.

[42] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997, doi: 10.1162/neco.1997.9.8.1735.

[43] K. Cho et al., “Learning phrase representations using RNN encoder–decoder for statistical machine translation,” in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, Doha, Qatar, 2014, pp. 1724–1734, doi: 10.3115/v1/D14-1179.

[44] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, New Orleans, LA, USA, 2019.

[45] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[46] A. Paszke et al., “PyTorch: An imperative style, high-performance deep learning library,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 32, Vancouver, BC, Canada, 2019, pp. 8024–8035.

[47] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, Sep. 2009, doi: 10.1109/TKDE.2008.239.

[48] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic minority over-sampling technique,” *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, Jun. 2002, doi: 10.1613/jair.953.

[49] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods,” in *Advances in Large Margin Classifiers*, A. J. Smola, P. Bartlett, B. Schölkopf, and D. Schuurmans, Eds. Cambridge, MA, USA: MIT Press, 1999, pp. 61–74.

[50] B. Zadrozny and C. Elkan, “Transforming classifier scores into accurate multiclass probability estimates,” in *Proc. 8th ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, Edmonton, AB, Canada, Jul. 2002, pp. 694–699, doi: 10.1145/775047.775151.

[51] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proc. 22nd Int. Conf. Mach. Learn. (ICML)*, Bonn, Germany, 2005, pp. 625–632, doi: 10.1145/1102351.1102430.

[52] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Trans. Knowl. Discov. Data*, vol. 6, no. 4, pp. 1–21, Dec. 2012, doi: 10.1145/2382577.2382579.

[53] P. Heidke, “Berechnung des Erfolges und der Güte der Windstärkevorhersagen im Sturmwarnungsdienst,” *Geogr. Ann.*, vol. 8, no. 4, pp. 301–349, Dec. 1926, doi: 10.1080/20014422.1926.11881138.

[54] C. A. Doswell, R. Davies-Jones, and D. L. Keller, “On summary measures of skill in rare event forecasting based on contingency tables,” *Weather Forecast.*, vol. 5, no. 4, pp. 576–585, Dec. 1990, doi: 10.1175/1520-0434(1990)005<0576:OSMOSI>2.0.CO;2.

[55] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLoS One*, vol. 10, no. 3, Art. no. e0118432, Mar. 2015, doi: 10.1371/journal.pone.0118432.

[56] J. Davis and M. Goadrich, “The relationship between precision-recall and ROC curves,” in *Proc. 23rd Int. Conf. Mach. Learn. (ICML)*, Pittsburgh, PA, USA, 2006, pp. 233–240, doi: 10.1145/1143844.1143874.

[57] G. W. Brier, “Verification of forecasts expressed in terms of probability,” *Mon. Weather Rev.*, vol. 78, no. 1, pp. 1–3, Jan. 1950, doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

[58] A. H. Murphy, “A new vector partition of the probability score,” *J. Appl. Meteorol.*, vol. 12, no. 4, pp. 595–600, Jun. 1973, doi: 10.1175/1520-0450(1973)012<0595:ANVPOT>2.0.CO;2.

[59] E. S. Epstein, “A scoring system for probability forecasts of ranked categories,” *J. Appl. Meteorol.*, vol. 8, no. 6, pp. 985–987, Dec. 1969, doi: 10.1175/1520-0450(1969)008<0985:ASSFPF>2.0.CO;2.

[60] H. R. Künsch, “The jackknife and the bootstrap for general stationary observations,” *Ann. Statist.*, vol. 17, no. 3, pp. 1217–1241, Sep. 1989, doi: 10.1214/aos/1176347265.

[61] D. S. Wilks, “Resampling hypothesis tests for autocorrelated fields,” *J. Climate*, vol. 10, no. 1, pp. 65–82, Jan. 1997, doi: 10.1175/1520-0442(1997)010<0065:RHTFAF>2.0.CO;2.

[62] L. S. Shapley, “A value for n-person games,” in *Contributions to the Theory of Games*, vol. II, H. W. Kuhn and A. W. Tucker, Eds. Princeton, NJ, USA: Princeton Univ. Press, 1953, pp. 307–317, doi: 10.1515/9781400881970-018.

Ata Sakik Ankara Üniversitesi Yazılım Mühendisliği Bölümü'nde 4. sınıf lisans öğrencisidir. Araştırma ilgi alanları makine öğrenmesi, açıklanabilir yapay zekâ ve bunların havacılık meteorolojisi ile operasyonel tahmin sistemlerine uygulanmasıdır.